

SYNTHÈSE DU MÉMOIRE DE DEA

*Développement d'une plate-forme intelligente d'aide à la détection du plagiat
et au choix d'un sujet de mémoire*

Présenté par

Moïse KASOMBO

Encadré par

Prof. MABELA ROSTIN

1. Description sommaire

Ce travail a consisté à développer une **plate-forme web intelligente** qui aide les enseignants et les étudiants de la Faculté des Sciences et Technologies de l'UNIKIN dans deux tâches essentielles :

1. Détecter automatiquement le plagiat dans les travaux académiques (TFC et mémoires). La plate-forme compare chaque nouveau travail avec tous les travaux déjà déposés et identifie les passages copiés ou paraphrasés, même lorsque les mots ont été changés.

2. Aider les étudiants à choisir un sujet de mémoire original. En analysant tous les travaux déjà réalisés dans le département, la plate-forme signale les sujets déjà traités (doublons) et suggère des thématiques qui n'ont pas encore été exploitées.

La plate-forme fonctionne entièrement en ligne, avec un espace d'administration permettant de gérer les facultés, départements, utilisateurs et documents **sans toucher au code source**. Elle est conçue pour être étendue progressivement à d'autres facultés et universités.

2. Problématique

Le plagiat académique est un problème grandissant à l'UNIKIN. Avec Internet, et surtout depuis l'arrivée d'outils comme **ChatGPT**, de plus en plus d'étudiants copient des contenus ou les font rédiger par une intelligence artificielle. Pourtant, la Faculté des Sciences et Technologies **ne dispose d'aucun outil** pour détecter ces pratiques. Les travaux sont archivés sans organisation, et il est impossible de vérifier si un étudiant a recopié le travail d'un autre.

Parallèlement, beaucoup d'étudiants **choisissent des sujets déjà traités** sans le savoir, parce qu'il n'existe aucun répertoire central des travaux antérieurs. Cela crée des doublons et diminue la qualité de la production scientifique.

Les outils existants ne conviennent pas au contexte local :

Turnitin et Compilatio sont **coûteux** (licences en devises étrangères)

Ils envoient les travaux étudiants vers des **serveurs étrangers** (confidentialité)

Ils ne sont pas adaptés au **contexte linguistique francophone** africain

Question centrale : Comment concevoir une solution **locale, intelligente et accessible**, capable à la fois de détecter le plagiat et d'aider au choix des sujets de mémoire ?

3. Objectifs

Objectif général

Concevoir une plate-forme web intelligente qui aide à la détection du plagiat et au choix des sujets de mémoire, avec une architecture modulaire extensible à d'autres universités.

Objectifs spécifiques :

Construire un **moteur de détection** capable d'identifier les copies, paraphrases et reformulations

Construire un **module de recommandation** qui évite les doublons et suggère des sujets originaux

Créer un **espace d'administration complet** pour gérer la plateforme sans programmation

4. Hypothèse

En utilisant l'**Intelligence Artificielle** pour comparer non pas les mots eux-mêmes mais le **sens des phrases**, la plateforme pourrait détecter le plagiat de manière plus efficace que les outils classiques, tout en identifiant les sujets déjà traités. L'**absence de fausses alertes** sur les travaux authentiques confirmerait la fiabilité de l'approche.

5. Méthode et technique utilisée

La démarche a combiné plusieurs méthodes : **Merise** pour concevoir la base de données, **UML** pour modéliser l'architecture logicielle, et une démarche **data science** pour la composante Intelligence Artificielle. Les données ont été collectées par **interviews** auprès du doyen et des enseignants, **observation** des procédures, et **expérimentation** sur un corpus de test.

La plateforme a été développée avec des technologies web modernes (Next.js, React, TypeScript). Le cœur intelligent utilise une technique d'IA appelée **TF-IDF** (qui représente le sens d'un texte sous forme de vecteurs mathématiques) combinée à la **similarité cosinus** (qui mesure la proximité entre deux textes). Cette approche permet de comparer le **sens** des passages plutôt que seulement les **mots**, ce qui rend la détection plus pertinente face aux paraphrases.

Innovations techniques de la plateforme :

- **Détection du plagiat par IA générative** : analyse du style d'écriture pour identifier les textes produits par ChatGPT
- **Fédération interuniversitaire** : la plateforme peut interroger les bases d'autres universités (UNILU, UCB, UNIKIS)
- **OCR automatique** : extraction du texte depuis les PDF scannés (Tesseract)
- **Architecture modulaire** : chaque faculté est un module indépendant, extensible sans modifier le code

6. Principaux résultats obtenus

La plateforme a été testée sur un corpus de **13 documents académiques** comprenant des travaux originaux, des paraphrases et des copier-coller. Les résultats sont les suivants :

Critère	Résultat
Plagiat correctement détecté (rappel)	100% (tous les cas)
Travaux originaux correctement identifiés (spécificité)	83% (1 faux positif sur 6)
Score global de fiabilité (F1-score)	93,3%
Vitesse de traitement par document	1 milliseconde
Document plagiat : score de similarité	77,8%
Document original : score de similarité	0% (aucune fausse alerte)

La plateforme est **opérationnelle** : elle compte **13 pages d'administration**, **19 routes API**, gère les facultés, départements, utilisateurs et documents, et génère des rapports automatiques. Le module de recommandation de sujets fonctionne également : il identifie correctement les sujets déjà traités et propose des thématiques inédites.

Comparée aux outils commerciaux comme Turnitin, la plateforme proposée offre l'avantage d'être **gratuite**, **locale** (données hébergées sur place), **adaptable** au contexte congolais, et dotée d'une fonctionnalité unique : l'**aide au choix de sujet**.

7. Limites du travail

Comme toute recherche, ce travail présente des limites qu'il convient de reconnaître :

Le corpus de test (13 documents) reste limité pour généraliser les résultats à grande échelle

La détection des textes produits par IA générative (ChatGPT) reste **partielle** : aucun outil au monde ne résout totalement ce défi à ce jour

L'approche TF-IDF, bien qu'efficace, pourrait être améliorée par des modèles plus avancés (Sentence-BERT)

Le déploiement à grande échelle nécessite une infrastructure serveur stable (PostgreSQL + pgvector)

8. Conclusion et perspectives

Ce travail a abouti à la création d'une **plate-forme intelligente fonctionnelle** qui répond à un besoin réel de l'UNIKIN : protéger l'intégrité académique tout en accompagnant les étudiants dans leurs recherches. Les résultats obtenus (93% de fiabilité, aucune fausse alerte sur les travaux originaux) valident l'hypothèse de départ et montrent que l'Intelligence Artificielle peut être mise au service de l'éducation en Afrique.

La plateforme ne se contente pas de détecter le plagiat : elle **transforme la gestion académique** en centralisant les travaux, en générant des rapports automatiques, et en aidant les étudiants à choisir des sujets originaux. Elle constitue une première brique vers un véritable écosystème universitaire intelligent congolais.

Perspectives d'évolution :

Étendre la plateforme à **toutes les facultés** de l'UNIKIN, puis à d'autres universités congolaises

Améliorer la détection des textes produits par **ChatGPT et autres IA génératives**

Constituer un **index national** des mémoires pour comparer les travaux entre universités

Intégrer des **modèles d'IA plus avancés** (Sentence-BERT multilingue) pour une meilleure détection sémantique

Créer un **assistant de rédaction scientifique** intégré pour accompagner les étudiants dès le début de leur travail