

SYNTHÈSE DU MÉMOIRE DE DEA

*Développement d'une plate-forme intelligente d'aide à la détection du plagiat
et au choix d'un sujet de mémoire*

Présenté par Moïse KASOMBO

Encadré par Professeur MABELA ROSTIN

Année académique 2025 - 2026

1. Description sommaire

Le présent travail consiste à développer une **plate-forme intelligente d'aide à la détection du plagiat et au choix d'un sujet de mémoire**, avec la Faculté des Sciences et Technologies de l'Université de Kinshasa comme cadre d'application. La plate-forme combine deux services IA complémentaires : (1) un moteur de détection automatique du plagiat basé sur la vectorisation TF-IDF et la similarité cosinus, capable d'identifier les copier-coller, paraphrases et reformulations dans les travaux académiques ; et (2) un module de recommandation de sujets de mémoire qui analyse le corpus des travaux existants pour éviter les doublons et identifier les thématiques sous-exploitées. La plate-forme offre également un back-office administrateur complet pour la gestion des facultés, départements, utilisateurs et documents, le tout sans intervention sur le code source.

2. Problématique

Le plagiat académique a pris une ampleur considérable avec l'avènement d'Internet et, plus récemment, des intelligences artificielles génératives (ChatGPT, Claude, Gemini). À la Faculté des Sciences et Technologies de l'Université de Kinshasa, aucun système informatique n'existe pour gérer et contrôler les travaux de fin de cycle (TFC) et les mémoires. Les travaux sont archivés de manière dispersée, sans indexation ni mécanisme de comparaison automatique. Parallèlement, les étudiants peinent à choisir des sujets originaux, faute d'un référentiel centralisé des travaux antérieurs. Les outils commerciaux (Turnitin, Compilatio) sont coûteux, dépendent de serveurs étrangers et ne prennent pas en compte les spécificités linguistiques et disciplinaires locales. Dès lors, comment concevoir une solution locale, intelligente et modulaire, capable à la fois de détecter le plagiat et d'assister le choix des sujets ?

3. Objectif général

Concevoir et développer une plate-forme web intelligente, fondée sur les techniques modernes d'Intelligence Artificielle, capable d'aider à la détection automatique du plagiat dans les travaux académiques et d'assister les étudiants dans le choix d'un sujet de mémoire, avec une architecture modulaire extensible à d'autres facultés et universités.

4. Objectifs spécifiques

- Développer un moteur IA de détection du plagiat basé sur la vectorisation TF-IDF et la similarité cosinus, avec classification des correspondances en cinq types (copier-coller, paraphrase, reformulation, traduction, similarité faible) ;
- Implémenter un module de recommandation de sujets de mémoire analysant le corpus existant pour détecter les doublons et identifier les thématiques sous-exploitées ;
- Concevoir un back-office administrateur complet permettant la gestion des facultés, départements, promotions, utilisateurs et documents sans intervention sur le code source ;
- Intégrer un système de génération automatique de rapports PDF imprimables pour les enseignants et jurys ;

- Évaluer quantitativement les performances du moteur IA (précision, rappel, F1-score) sur un corpus pilote de travaux académiques.

5. Hypothèse

Le développement d'une plate-forme intelligente fondée sur la vectorisation TF-IDF et la similarité cosinus permettrait de détecter de manière efficace le plagiat par paraphrase dans les travaux académiques, tout en offrant, grâce à l'analyse thématique du même corpus, une assistance pertinente au choix des sujets de mémoire. L'absence de faux positifs sur les documents originaux et la détection des correspondances entre documents plagiat valideraient l'approche proposée.

6. Méthode et technique utilisée

La démarche méthodologique combine la méthode **Merise** pour la modélisation du système d'information, la méthodologie **CRISP-DM** pour la composante IA, et le framework **UML** pour la conception orientée objet. Les techniques de collecte incluent l'interview, l'observation, la technique documentaire et l'expérimentation. La stack technique comprend :

- **Frontend** : Next.js 16, React 19, TypeScript, Tailwind CSS 4, shadcn/ui
- **Backend** : API Routes Next.js, authentification JWT (jose), validation Zod
- **Moteur IA** : TF-IDF natif TypeScript, similarité cosinus, Jaccard lexical, classification 5 types
- **Détection IA générative** : analyse stylométrique (burstiness, TTR, perplexité proxy)
- **Persistance** : JSON store local (démon), PostgreSQL + pgvector (production via Docker Compose)
- **OCR** : Tesseract + pdfplumber (mini-service Python FastAPI)
- **Fédération interuniversitaire** : API REST entre établissements partenaires

7. Principaux résultats obtenus

L'évaluation sur un corpus pilote de 13 documents académiques (6 originaux, 4 sources plagiées, 2 paraphrases, 1 copier-coller) a produit les résultats suivants :

Métrique	Moteur sémantique	Baseline lexicale
Précision	87,5%	87,5%
Rappel	100,0%	100,0%
F1-score	93,3%	93,3%
Exactitude	92,3%	92,3%
Spécificité	83,3%	83,3%

Le document plagiat a obtenu un score de **77,8%** (2/2 segments matchés), tandis que le document original sur un sujet différent a obtenu **0%** — confirmant l'absence de faux positifs. Le temps de traitement est de **1 milliseconde** par document. Le module de recommandation a correctement identifié les sujets proches de travaux existants et suggéré des thématiques sous-exploitées. La plate-forme compte **13 pages admin**, **19 routes API**, et un code source d'environ **5 000 lignes** versionné sur GitHub.

8. Conclusion et perspectives

Ce travail a abouti au développement d'une plate-forme intelligente opérationnelle, intégrant deux services IA complémentaires : la détection automatique du plagiat et la recommandation de sujets de mémoire. Les résultats obtenus (F1-score = 93,3%, rappel = 100%) valident l'hypothèse de recherche et démontrent la pertinence de l'approche TF-IDF combinée à la similarité cosinus pour le contexte académique congolais.

Les perspectives d'évolution incluent : (1) l'intégration de Sentence-BERT multilingue pour une similarité sémantique plus profonde ; (2) la détection du plagiat par IA générative via classificateurs stylométriques ; (3) le déploiement sur PostgreSQL avec pgvector pour la production ; (4) l'extension à d'autres facultés de l'UNIKIN puis à d'autres universités congolaises via l'API fédératrice interuniversitaire ; et (5) la constitution d'un index national des mémoires pour la détection interuniversitaire du plagiat.

